IMPLEMENTACIÓN DE GUARDARAILS EN MODELOS DE AZURE Y PROBLEMAS AL DESARROLLAR EL PROYECTO

Jaime Novillo Benito

Implementar guardrails en modelos 1
Problemas 1

Implementar guardrails en modelos

Primero buscamos el modelo al que se lo queremos implementar en “Modelos” y le damos “Guardrail”

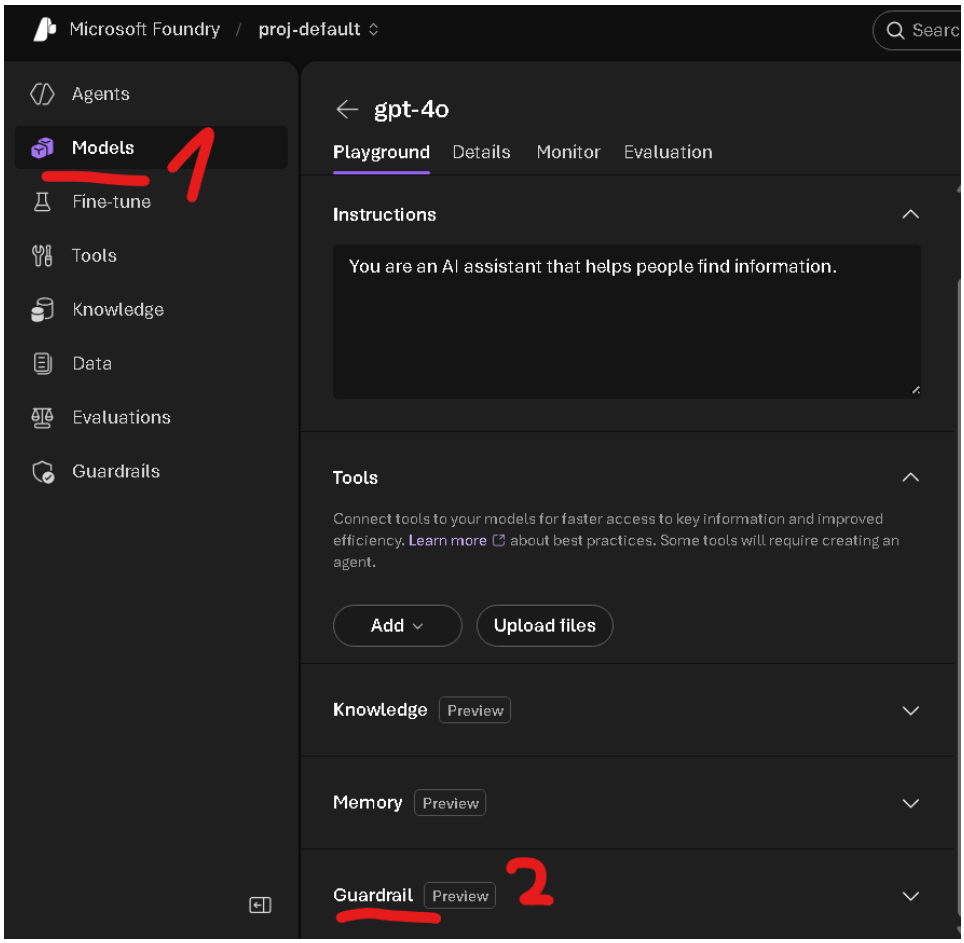

Le damos a “Edit guardrail”, para modificar el qué viene por predeterminado (al modificarlo se guardará como otro por separado)

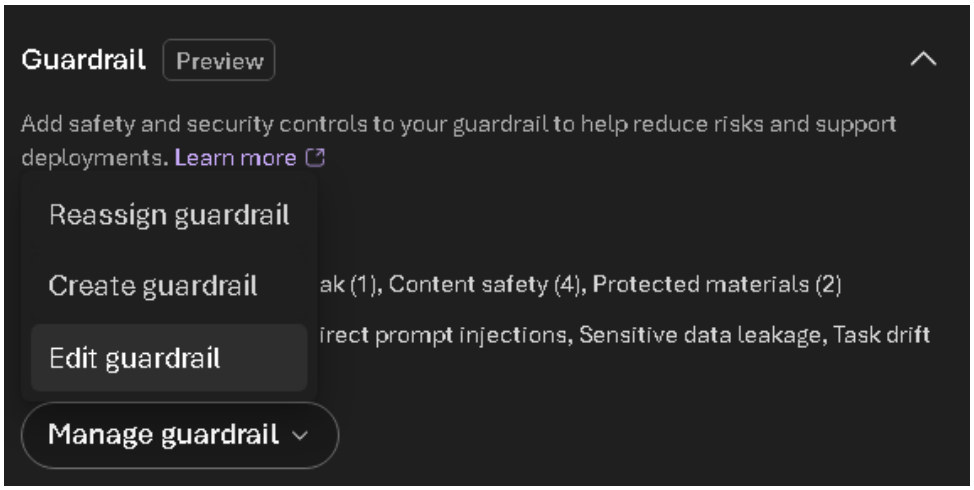

1. Podemos ver los filtros y en algunos casos cómo de estrictos son
2. Risk: seleccionamos el tipo de riesgo a añadir o modificar
3. Ajustamos el nivel (si ya existía dentro del guardrail nos dará la opción de sobrescribirlo)
4. Cuándo queremos que se haga la comprobación, por defecto viene que compruebe el input y output
5. Añadir o aplicar el control

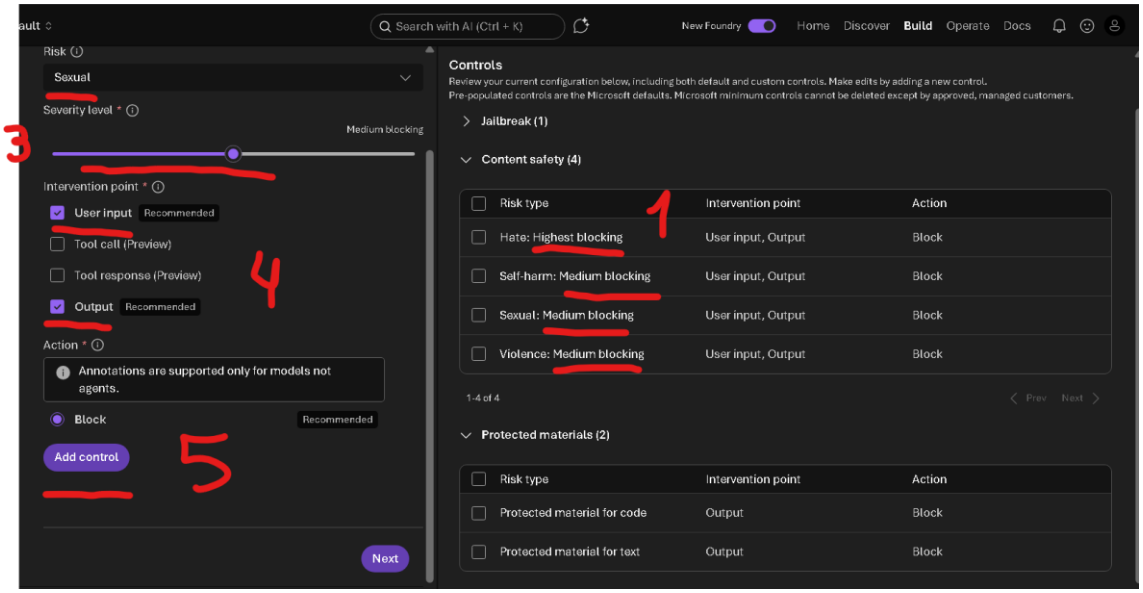

Aquí nos sale, en caso de que exista, si queremos sobrescribirlo

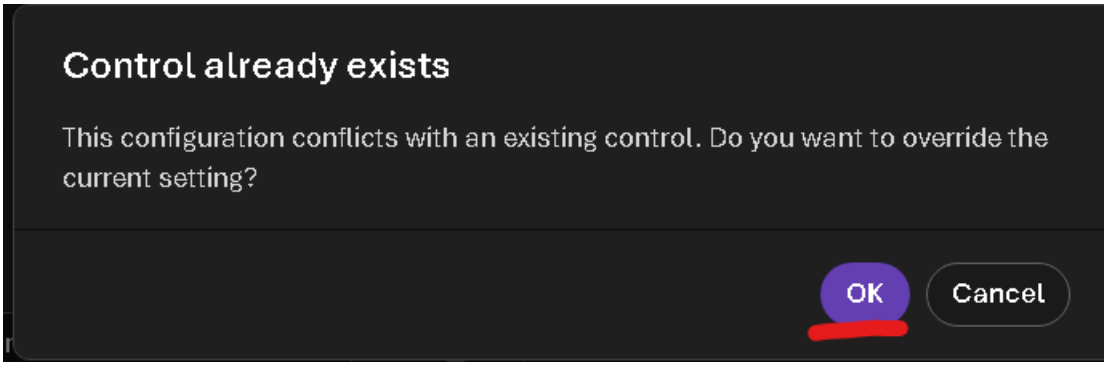

En mi caso he subido al máximo “Hate”

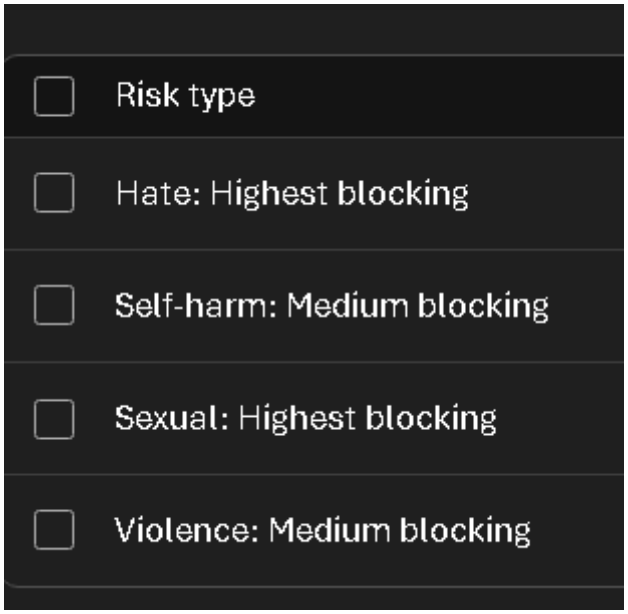

Seleccionamos el modelo al que se va a aplicar y damos a “Next”

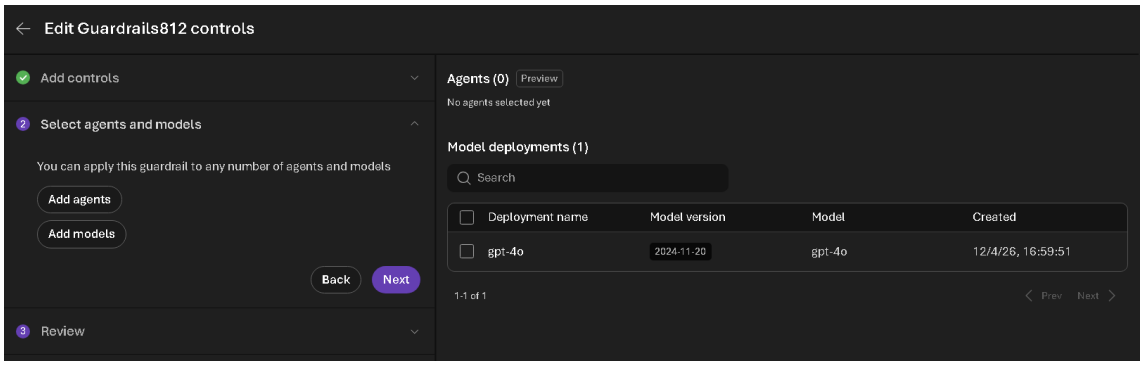

Y por último le damos a “Submit”

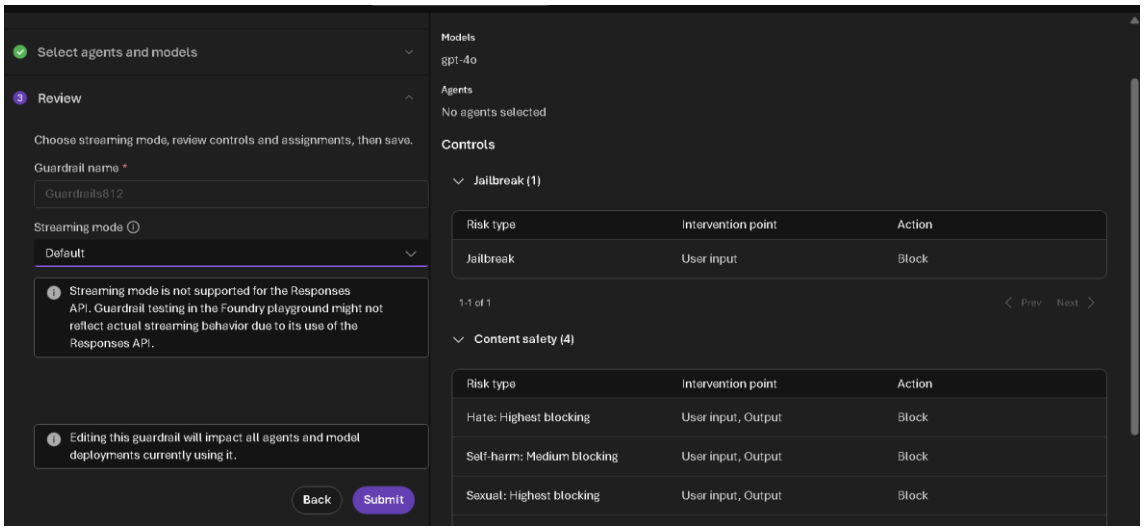

Y ahora, si probamos a hacer una pregunta con indicios de odio en vez de decir que es inapropiado, devuelve un error directamente

```
Enviando a modelo ...
Error: Error code: 400 - {'error': {'message': "The response was filtered due to the prompt triggering Azure OpenAI's content manageme

RESULTADO:

✅ Azure Guardrails DE HATE está FUNCIONANDO CORRECTAMENTE
```

Problemas

- No todos los modelos permiten ajustar por (por ejemplo los mini): low, medium o high

- Probé a hacer la parte de audio con GPT-4 y 5, pero finalmente tuve que usar el modelo multimodal de Phi

- Al intentar hacer que saltara el guardrail hecho en Azure, primero se activaba el interno del propio modelo